토르 브라우저 핑거프린팅

https://youtu.be/K_wOzprPUXI

Contents

CryptoCraft LAB

목표

- 인터넷을 사용하는 사용자가 어느 사이트에 접속하는지 확인

- 해당 사이트의 카테고리(뉴스, 부동산 등)에 대한 분류를 통해 사용자에 대한 핑거프린팅 진행

배경

- 전송 중인 패킷을 가로채서 하는 분석은 암호화가 많이 되어 있기에 어려움

- 사용자의 PC에서 직접 발생하는 패킷을 이용하여 분석

실험 환경

- 가상머신 (VMware Workstation 15 Player (Non-commercial use only))
- Ubuntu 64-bit 16.04 LTS
- Torsocks 2.1.0
- Intel® Core™ i3-8145U CPU @ 2.10GHz

Torsocks

- CUI 기반
- 토르 네트워크를 이용한 SOCKS 애플리케이션

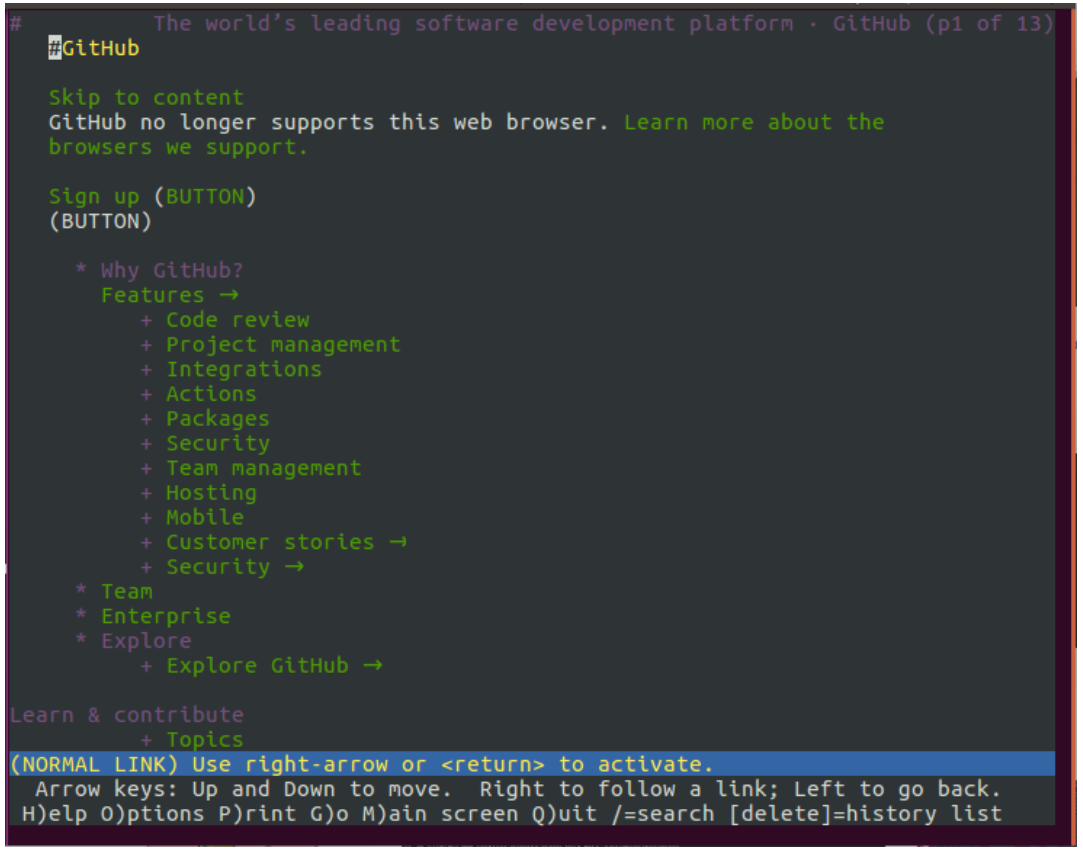

Torsocks를 이용해 Github에 접속

SOCKS

- **SOCK**et **S**ecure Protocol
- SOCKS 서버는 클라이언트의 요청을 받아 클라이언트와 서버 사이에서 릴레이
- 네트워크 방화벽이 도입되면서 인터넷이 내부와 외부로 나뉘게 되고, 이를 통과할 수 있도록 하는 프레임워크 및 강력한 인증이 필요해지면서 등장
- SOCKSv4는 TCP 기반으로 작동
- SOCKSv5는 UDP에서도 작동하도록 확장 및 IPv6 주소화 방식 사용 가능

이용 프로그램

- https://github.com/wisepythagoras/website-fingerprinting.git

- 캡처 프로그램을 실행시킨 뒤 torsocks를 통해 페이지를 접속하며 패킷 수집

- 수집된 패킷을 학습 (머신러닝) 및 분류 (kNN)

수집 자동화

- 파이썬 매크로 프로그램 작성을 통해 수집 자동화

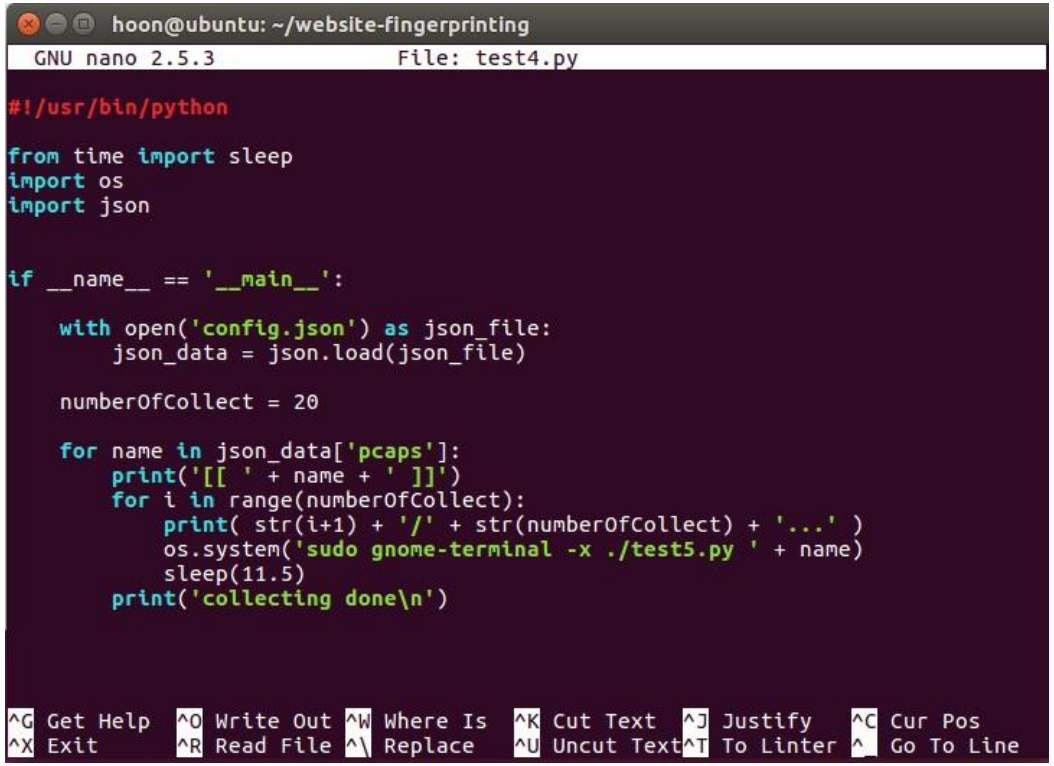

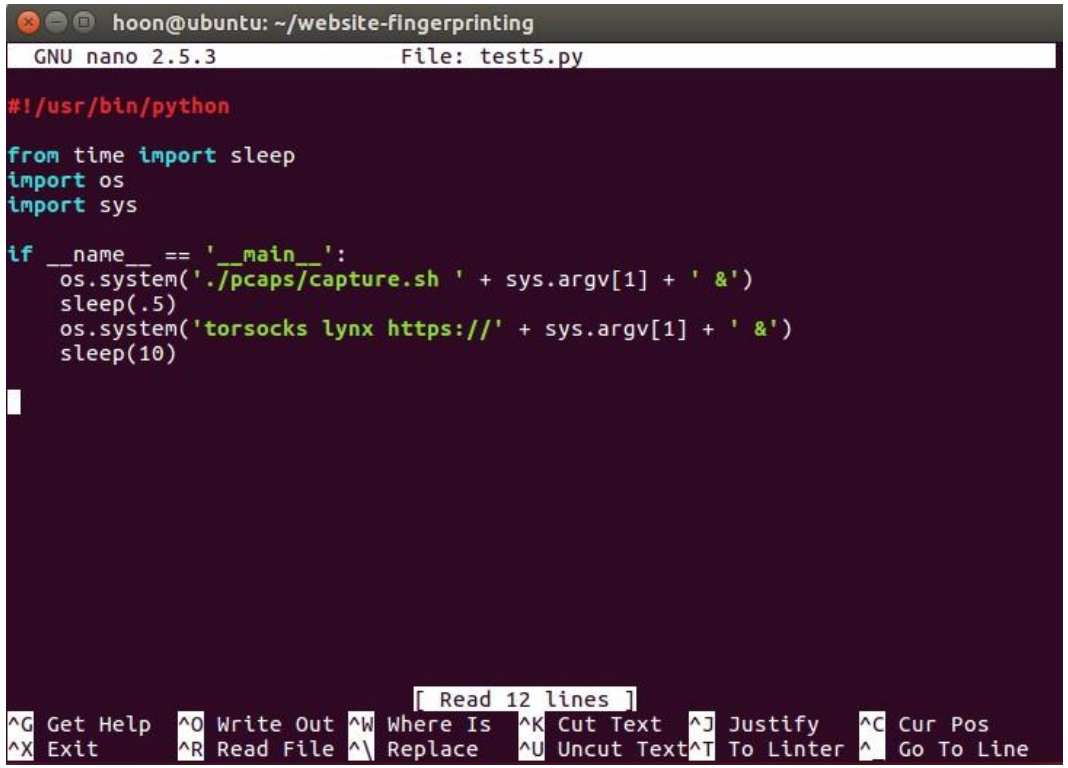

하위주소가 다를 경우에 대한 구분

- 이용 웹사이트 : MSN (https://www.msn.com/)
- 원래는 접속 지역에 따라 패킷 구분이 가능한지를 파악하려고 했으나, 의도와 다른 결과 얻음
- msn 사이트에 접속할 경우 접속 지역에 따라서 각기 다른 하위주소로 연결됨
  (ex. https://www.msn.com/ko-kr/, https://www.msn.com/en-us 등등)
- 이를 이용하여 각기 다른 exit relay에 대해 패킷 수집 및 분석

하위주소가 다를 경우에 대한 구분 - case #1

- case 1

- 하위주소를 직접 입력하여 접속한 사이트들에 대한 구분

- msn.com 으로 접속하는 것이 아닌, msn.com/ko-kr/ msn.com/en-us/ 처럼 하위주소까지 입력하여 접속하여 패킷 확보

- msn.com/ko-kr/ 과 msn.com/en-us/ 등 각기 다른 하위주소에 대한 구분이 가능한지에 대한 실험

하위주소가 다를 경우에 대한 구분 - case #1

- ko-kr (한국)
- en-us (미국)
- ja-jp (일본)
- zh-cn (중국)
- de-at (오스트리아)
- fr-fr (프랑스)
- es-es (스페인)
- it-it (이탈리아)
- nl-nl (네덜란드)
- da-dk (덴마크)
- 수집 및 학습에 이용된 하위주소 총 10개

하위주소가 다를 경우에 대한 구분 - case #1

- 서로에 대한 구분 가능

- 전체 패킷을 이용해 학습을 시킨 뒤, ko-kr이나 en-us 등의 하위주소에 따라 구분 가능

하위주소가 다를 경우에 대한 구분 - case #2

- case 2

- 하위주소를 입력하지 않고 접속한 사이트들에 대한 구분
- msn.com 으로 접속하여 리다이렉트된 하위주소의 패킷을 얻음
- exit relay가 랜덤으로 잡히기 때문에, 위치를 특정해서 얻지는 못함

하위주소가 다를 경우에 대한 구분 - case #2

- en-xl
- de-at
- fr-fr
- it-it
- 수집 및 학습에 이용된 하위주소 총 4개

- 결과 : 서로에 대한 구분 가능

하위주소가 다를 경우에 대한 구분 - case #3

- case 3

- msn.com으로 접속해서 학습시킨 분류기가 msn.com/URL/ 으로 접속해서 얻은 패킷을 구분하는지

- 반대의 경우도 성립하는지

- 결과 : 구분하지 못함 (아예 msn으로 인식하지 못함)

포털별 서비스에 대한 분류

- 포털 사이트들의 하위 서비스 사이트들이 각 포털 사이트로 분류가 되는지 테스트

- 학습이 되지 않은 패킷을 이용하기에, 일종의 오픈월드 테스트로 볼 수 있음

수집 웹사이트

- 네이버(64개), 다음(46개), 네이트(34개)의 하위 사이트를 수집에 이용

수집 웹사이트

- 크롤링을 통해 URL 수집

```java
public static void naver() throws Exception {

    final String html = " HTML ELEMENTS ";
    Document doc = Jsoup.parse(html);
    Elements elem = doc.select("#category-div");

    HashSet<String> set = new HashSet<>();
    Elements as = elem.select("a");
    for (Element a : as) {
        String href = a.attr("href");
        int cut;
        if ( href.startsWith("https") ) cut = 8;
        else cut = 7;
        href = href.substring(cut);
        try {
            href = href.substring(0, href.indexOf("/"));
            set.add(href);
        } catch (StringIndexOutOfBoundsException e) {
            set.add(href);
        }
    }

    for (String s : set) {
        System.out.println( "\"" + s + "\"," );
    }
}
```

```java
public static void kakao() throws Exception {

    Document doc = Jsoup.connect("https://www.daum.net/sitemap/index.html").get();
    Elements elem = doc.select("#mArticle > div.box_sitemap");

    HashSet<String> set = new HashSet<>();
    Elements lis = elem.select("li");
    for (Element li : lis) {
        String href = li.child(0).attr("href");
        int cut;
        if ( href.startsWith("https") ) cut = 8;
        else cut = 7;
        href = href.substring(cut);
        try {
            href = href.substring(0, href.indexOf("/"));
            set.add(href);
        } catch (StringIndexOutOfBoundsException e) {
            set.add(href);
        }
    }

    for (String s : set) {
        System.out.println( "\"" + s + "\"," );
    }
}
```

```java
public static void nate() throws Exception {

    Document doc = Jsoup.connect("https://www.nate.com/sitemap/index.html").get();
    Elements elem = doc.select("#list0 > ul");

    HashSet<String> set = new HashSet<>();
    Elements as = elem.select("a");
    for (Element a : as) {
        String href = a.attr("href");
        int cut;
        if ( href.startsWith("https") ) cut = 8;
        else if ( href.startsWith("http") ) cut = 7;
        else cut = 2;
        href = href.substring(cut);
        try {
            href = href.substring(0, href.indexOf("/"));
            set.add(href);
        } catch (StringIndexOutOfBoundsException e) {
            set.add(href);
        }
    }

    for (String s : set) {
        System.out.println( "\"" + s + "\"," );
    }
}
```

실험 세팅

- 패킷 수집 시간 15초
- 패킷 개수 100개
- 사이트별로 서비스를 2,3개로 나눈 뒤 1개를 제외하고 전체를 학습시킨 뒤 그 1개가 가리키는 곳을 바탕으로 성공 여부를 판단
- ex. 네이버 64개 서비스를 22개, 22개, 20개로 나눈 뒤 첫 22개를 제외한 42개를 나머지 서비스들과 함께 학습에 이용한 뒤, 제외시켰던 22개 서비스를 분류
- 분류 기준 : 네이버 64개를 전부 “네이버” 카테고리로 묶은 뒤 “네이버”를 가리키면 분류

추가 수집 데이터

- 네이버, 다음, 네이트 외에 Alexa’s top sites 10개 데이터 추가
- https://www.alexa.com/topsites
- tmail.com과 login.tmail.com은 중복될 수 있으므로 제외
- 11위의 360.cn 추가

	Site
1	Google.com
2	Youtube.com
3	Tmall.com
4	Baidu.com
5	Qq.com
6	Facebook.com
7	Sohu.com
8	Login.tmall.com
9	Taobao.com
10	Yahoo.com
11	360.cn

결과

- 네이버 정답률 : 53/64 (82.81%)
- 카카오 정답률 : 18/46 (39.13%)
- 네이트 정답률 : 8/34 (23.53%)
- 네이버는 높은 정답률을 보였으나, 나머지는 높지 않음

가정

- 서버의 물리적 위치가 분류에 영향을 줄 수 있지 않을까?

서버의 물리적 위치

- IP 주소를 이용해 WHOIS를 통해 서버의 물리적 위치 조회
- WHOIS 오픈API를 이용해 파이썬으로 물리적 위치 정보 확보

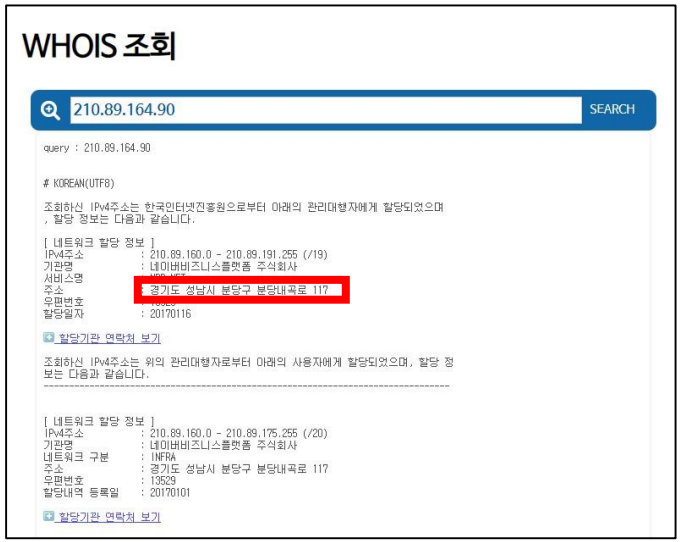

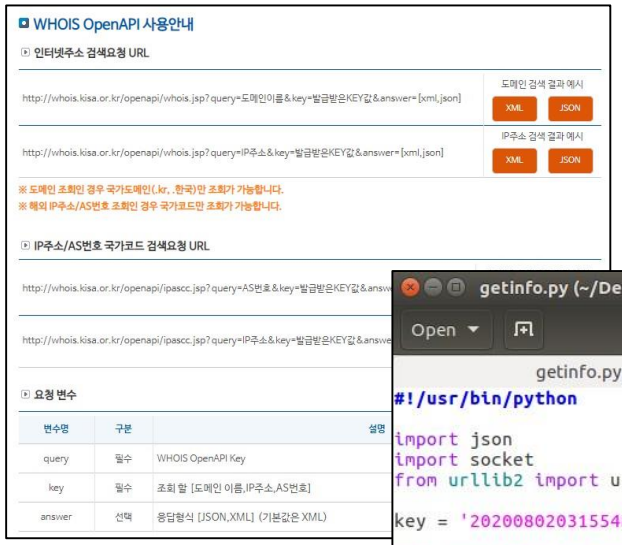

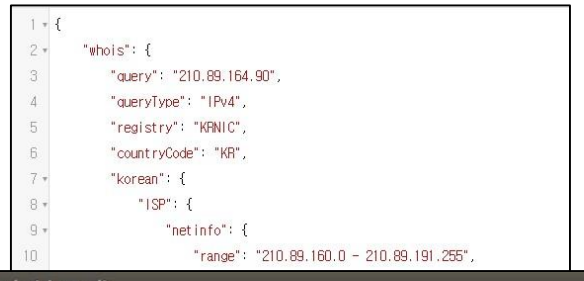

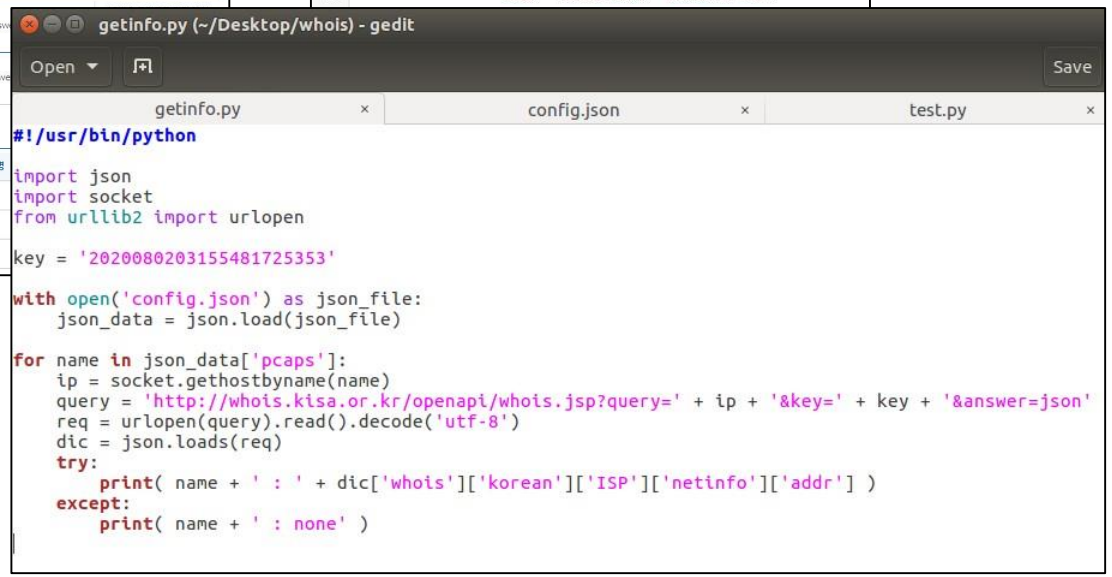

서버의 물리적 위치

- 네이버, 다음, 네이트 하위 서비스들을 물리적 위치에 따라 구분한 결과 얻어낸 주소는 7개

- 서울특별시 용산구
- 서울특별시 중구
- 서울특별시 구로구
- 용인시 수지구
- 성남시 분당구 분당내곡로
- 성남시 분당구 불정로
- 제주시 첨단로

서버의 물리적 위치

- 각 위치별로 2,3묶음으로 나누어서 제대로 가리키는지에 대해 확인해본 결과

- 서울특별시 용산구 1/13 (7.69%)
- 서울특별시 중구 0/20 (0%)
- 서울특별시 구로구 2/12 (16.67%)
- 용인시 수지구 2/15 (13.33%)
- 성남시 분당구 분당내곡로 30/52 (57.69%)
- 성남시 분당구 불정로 5/24 (20.83%)
- 제주시 첨단로 0/8 (0%)

향후 연구 계획

- 뉴스, 부동산 등과 같이 특정 카테고리로 묶을 수 있는지

- “Improved Website Fingerprinting on Tor” 논문에서 언급된 방식을 통해 분류 진행

Q & A