

# Variational AutoEncoder

:변이형 오토인코더

강예준

<https://youtu.be/nmDXpl8lGOs>

AutoEncoder

AutoEncoder와 Variational AutoEncoder의 차이점

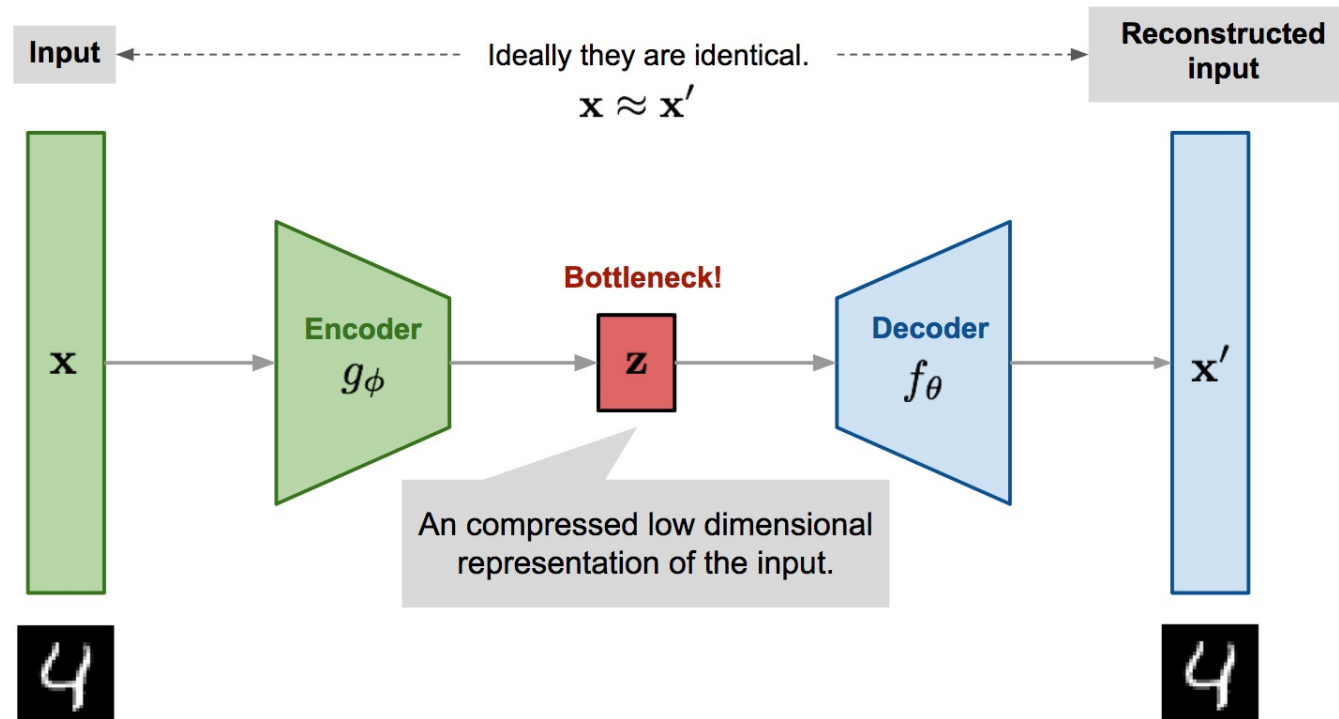
Variational AutoEncoder

Variational AutoEncoder in Pytorch

# AutoEncoder

- **AutoEncoder**



- Encoder : 입력한 데이터  $x$ 를 **특징 값**으로 변환하는 신경망
- Decoder : 인코더 과정을 거쳐 나온 출력값을 디코더에 입력 시, 인코더 과정을 거치기 전 데이터인  $x$ 값 **출력**




# AutoEncoder와 Variational AutoEncoder

- AutoEncoder와 Variational AutoEncoder의 차이점

- AutoEncoder : 잠재변수를 고정된 값(표현 벡터)으로 표현
- Variational AutoEncoder : 잠재변수를 가우시안 확률분포(정규분포) 값의 범위로 제공



AE




vs.

VAE

# AutoEncoder와 Variational AutoEncoder

- AutoEncoder와 Variational AutoEncoder의 차이점

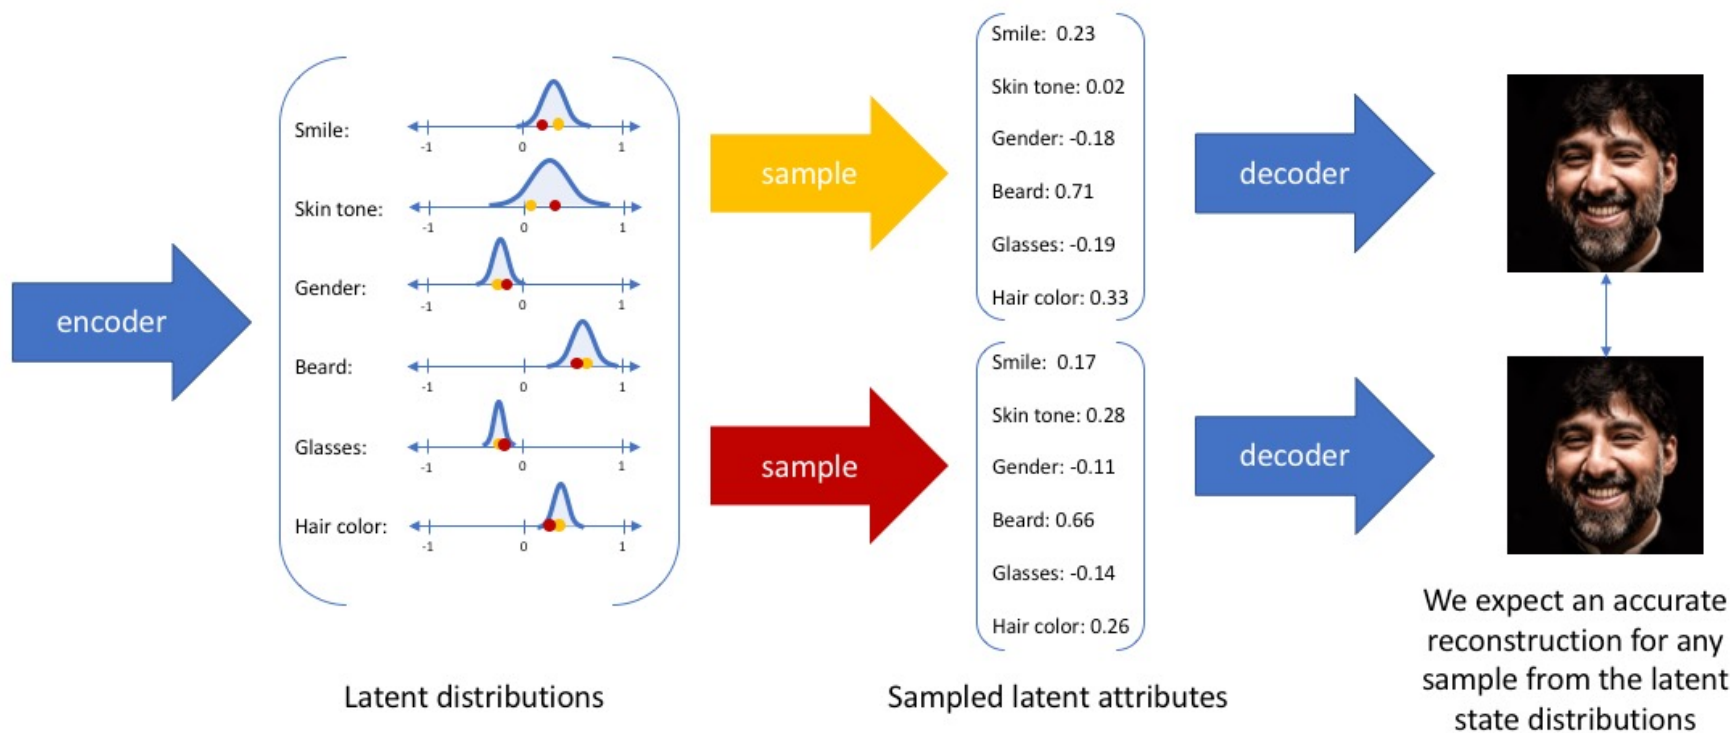
- AutoEncoder의 목적 : 입력 데이터의 압축을 통해, 데이터의 중요한 **특징을 추출** (Manifold Learning)
- Variational Auto Encoder의 목적 : 디코더를 학습 시켜 새로운 **이미지를 생성** (Generative Model)



# Variational AutoEncoder

- **Variational AutoEncoder**

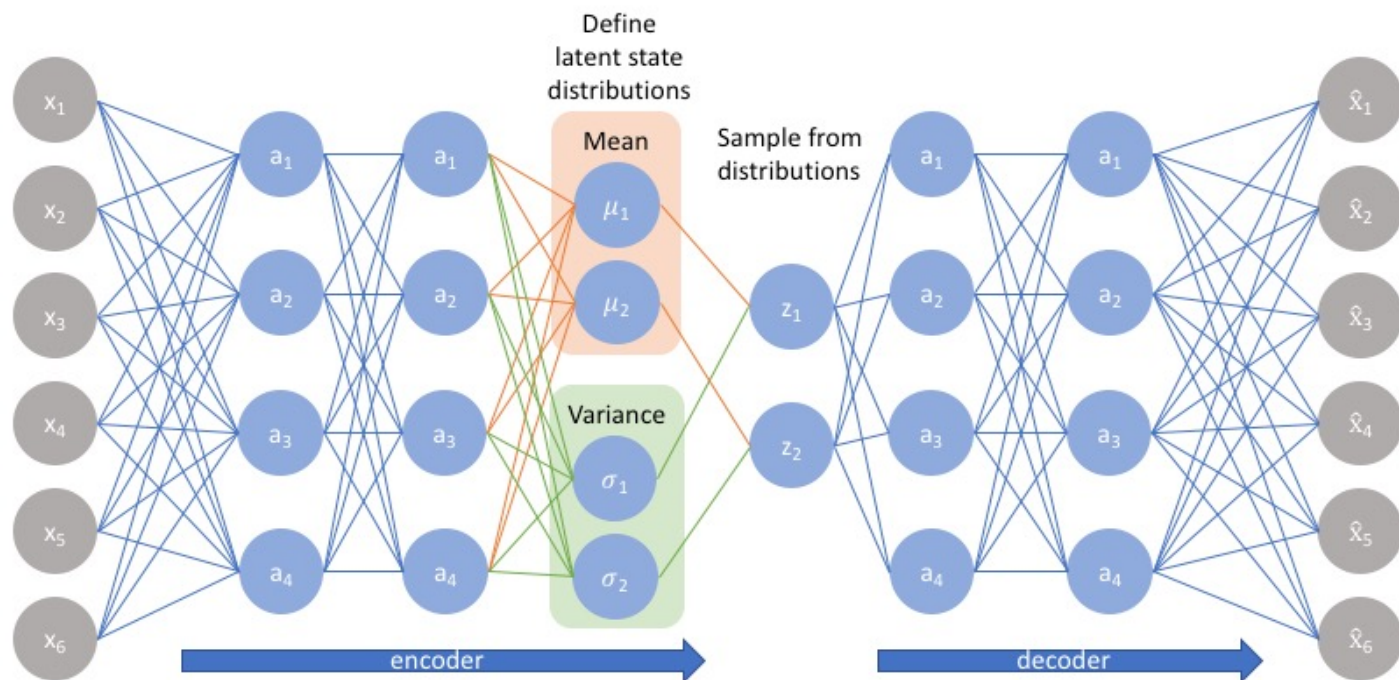
- Encoder : 입력한 데이터  $x$ 를 정규분포(평균,표준편차)로 변환하는 신경망
- Decoder : 인코더 과정을 거쳐 나온 출력값을 디코더에 입력 시, 인코더 과정을 거치기 전 데이터인  $x$ 값 출력



# Variational AutoEncoder

- Variational AutoEncoder

- Encoder가 만들어낸  $z$ 의 평균과 표준편차를 모수로 하는 **정규분포**로부터 랜덤으로 샘플링하여 잠재변수  $z$ 를 생성
- 잠재변수  $z$ 를 통해, 디코더가 새로운 데이터를 생성 (생성형 모델)
  - 대표적인 생성형 모델 GAN과 비교하였을 때, 출력이 흐릿하지만 평가기준이 명확하며 학습이 안정적



# Loss Function of VAE

- **Loss Function of Decoder (Reconstruction Error)**

- 원본 이미지와 생성된 이미지와의 오차
- 잠재변수  $z$ 값으로 얼마나 원본 이미지와 유사한 이미지를 잘 생성하는가?

- **Loss Function of Encoder (Regularization)**

- 원본 이미지 확률분포와 잠재변수 확률분포 사이의 오차
- 잠재변수  $z$ 값이 원본 이미지의 확률분포와 얼마나 유사한가?

$$L_i(\phi, \theta, x_i) = \underbrace{-\mathbb{E}_{q_\phi(z|x_i)}[\log(p_\theta(x_i|z))]}_{\text{Reconstruction Error}} + \underbrace{KL(q_\phi(z|x_i)||p(z))}_{\text{Regularization}}$$



# Variational AutoEncoder in Pytorch

```
1 # Model
2 class VAE(nn.Module):
3     def __init__(self, latent_dim=20, hidden_dim=500):
4         super(VAE, self).__init__()
5         self.fc_e = nn.Linear(784, hidden_dim)
6         self.fc_mean = nn.Linear(hidden_dim, latent_dim)
7         self.fc_logvar = nn.Linear(hidden_dim, latent_dim)
8         self.fc_d1 = nn.Linear(latent_dim, hidden_dim)
9         self.fc_d2 = nn.Linear(hidden_dim, 784)
10
11     def encoder(self, x_in):
12         x = F.relu(self.fc_e(x_in.view(-1, 784)))
13         mean = self.fc_mean(x)
14         logvar = self.fc_logvar(x)
15         return mean, logvar
16
17     def decoder(self, z):
18         z = F.relu(self.fc_d1(z))
19         x_out = F.sigmoid(self.fc_d2(z))
20         return x_out.view(-1, 1, 28, 28)
21
22     def sample_normal(self, mean, logvar):
23         # Using torch.normal(means, sds) returns a stochastic tensor which we cannot backpropagate through.
24         # Instead we utilize the 'reparameterization trick'.
25         # http://stats.stackexchange.com/a/205336
26         # http://dpkingma.com/wordpress/wp-content/uploads/2015/12/talk_nips_workshop_2015.pdf
27         sd = torch.exp(logvar*0.5)
28         e = Variable(torch.randn(sd.size())) # Sample from standard normal
29         z = e.mul(sd).add_(mean)
30         return z
31
32     def forward(self, x_in):
33         z_mean, z_logvar = self.encoder(x_in)
34         z = self.sample_normal(z_mean, z_logvar)
35         x_out = self.decoder(z)
36         return x_out, z_mean, z_logvar
37
38 model = VAE()
```

➡ 인코더의 출력 : 평균, 표준편차

➡ 오토인코더와 달리 정규분포로부터 잠재변수  $z$  생성

# Variational AutoEncoder in Pytorch

```
1 # Loss function
2 def criterion(x_out,x_in,z_mu,z_logvar):
3     bce_loss = F.binary_cross_entropy(x_out,x_in,size_average=False)
4     kld_loss = -0.5 * torch.sum(1 + z_logvar - (z_mu ** 2) - torch.exp(z_logvar))
5     loss = (bce_loss + kld_loss) / x_out.size(0) # normalize by batch size
6     return loss
```



Loss Function of VAE



VAE의 입력과 출력값

Q & A